

多数据源用户数据批量合并脚本-功能需求文档

1. 文档概述

本文档为**多数据源用户数据批量合并脚本**功能需求说明，明确脚本输入规则、目录文件规范、核心合并逻辑、输出目录规则、约束条件及输出要求。脚本支持配置多个数据源目录，按「单数据源内部合并、多数据源跨目录合并」两级逻辑，完成同用户、同通道时序数据文件的自动合并，对时间区间重叠数据进行告警跳过，同时严格沿用原始数据源目录结构输出合并结果，实现多源用户数据的规整整合与结构化归档。

2. 目录与文件规范

2.1 目录结构

脚本支持输入多个数据源根目录，每个数据源根目录下包含若干独立用户数据目录，整体层级结构统一规范，且最终输出目录完全对齐该原始结构：

- 数据源根目录：自定义多源输入目录
- 用户数据目录：命名格式为 **终端号_用户号**，示例：`800080252844_4206894986488`
- 用户目录内部：存储单个用户、单通道/多通道的待合并CSV数据文件

2.2 数据文件命名规范

待合并数据文件命名严格遵循固定格式，用于解析用户、设备、通道及时间维度信息：

命名格式： `e241_<终端号>_<用户号>-Ch<通道号>-<起始时间>-<截止时间>.csv`

时间格式：YYmmdd（两位年份+月份+日期）

示例： `e241_800080252844_4206894986488-Ch1-260604-260611.csv`

合并匹配依据：仅**终端号**、**用户号**、**通道号**完全一致的文件，允许参与合并运算。

3. 整体功能流程

脚本整体执行分为两大核心阶段，串行执行：**先完成单数据源内部数据合并，再执行多数据源跨目录数据合并**，所有合并结果严格按照原始数据源、用户目录层级结构规整输出。

- 阶段一：遍历每个独立数据源目录，完成目录内所有用户、同通道数据的迭代合并，按原目录结构生成单源合并结果文件
- 阶段二：基于各数据源合并完成后的文件，匹配多数据源中相同用户、相同通道数据，完成跨数据源合并，最终统一结构化输出

4. 详细功能规则

4.1 单数据源内部数据合并规则

针对单个数据源根目录下的所有用户数据，逐用户、逐通道执行批量合并：

1. 遍历数据源下所有「终端号_用户号」用户目录，按**用户+通道**对数据文件分组；
2. 若分组内仅存在单个文件，无需合并，直接保留原文件；
3. 若分组内存在多个文件，采用**迭代两两合并**逻辑：
 - 取出两个待合并文件，解析文件名中的起止时间区间；
 - **时间校验**：判断两个文件时间区间是否重叠；
 - 无重叠：合并两份数据，生成新文件。新文件起始时间取两者最早时间，截止时间取两者最晚时间，沿用标准命名格式；再将新文件与组内剩余文件继续迭代合并，直至该分组所有文件合并完成；
 - 有重叠：立即终止当前用户通道的合并任务，输出告警日志，跳过该组所有数据，不生成合并文件。

4.2 多数据源跨目录数据合并规则

所有数据源内部合并完成后，执行跨数据源同用户数据合并：

1. 跨源匹配条件：不同数据源目录下，**用户目录名称（终端号_用户号）、通道号**完全一致；
2. 对匹配成功的跨源文件，完全复用**4.1 时间校验与合并规则**；
3. 无时间重叠则迭代合并、更新文件时间区间；存在时间重叠则告警并跳过当前用户通道的跨源合并。

5. 核心约束条件

- 合并唯一性约束：仅同终端号、同用户号、同通道号的数据文件支持合并，不同通道数据相互独立、不参与合并；
- 时间强约束：任意两轮待合并文件时间区间存在重叠，即刻终止当前批次合并，不强制合并、不覆盖数据；
- 执行顺序约束：必须先完成单数据源内部全量合并，再执行跨数据源合并，不可逆序、不可并行执行；
- 命名约束：所有合并生成的新文件，严格遵循原始文件命名规范，仅更新起止时间字段；
- 目录结构约束：输出目录严格复刻原始数据源层级结构，保留「数据源根目录-终端号_用户号用户目录」完整层级，不打乱、不扁平化目录结构，保证数据溯源清晰。

6. 脚本输入与输出

6.1 输入参数

- 必填：支持配置**多个数据源根目录路径**，批量读取多源数据；
- 可选：自定义结果输出目录、日志存储目录、是否保留原始文件。

6.2 输出内容

- 结构化合并数据文件：在自定义输出目录下，**完全复刻原始多数据源目录结构**，按「数据源根目录-用户目录」层级存储对应合并后的CSV文件，目录层级、命名与输入源保持一致；
- 各级合并完成的标准CSV数据文件；
- 完整运行日志，区分「数据源内部合并、跨数据源合并」记录；
- 异常告警日志，精准记录重叠数据的数据源路径、用户目录、文件名、冲突时间区间。

7. 功能特性总结

- 支持多数据源批量导入，适配多源分散存储的用户数据场景；
- 严格基于文件名规则解析维度信息，实现自动化分组、匹配、合并；
- 双层合并逻辑，先内源、后跨源，保证数据整合完整性；
- 时间重叠自动校验告警，规避数据重复、数据错乱问题；
- 全流程日志记录，便于问题追溯、数据校验与复盘；
- 结构化目录输出，完全对齐原始数据源目录层级，数据归档规范、溯源便捷。

（注：部分内容可能由 AI 生成）