

工商业负荷辨识算法开发指南

——基于总线/分路低频时序数据的 Agent 自动研发与接口契约

适用场景：工业/商业多相复杂负荷；总线 5 分钟、分路 15 分钟；Windows + Conda；可作为 AI Agent 自动研发平台的项目级开发规格。

0. 本次校核结论与使用原则

本版以《数据输入输出及配置要求.md》作为输入/输出/配置接口的最高优先级约束，同时保留上一版 0~27 点的算法研发主流程。对发现的接口冲突、命名不一致和重复内容进行了统一。

- 实际原始输入目录统一采用 `data/trains/<device>_<user>/` 与 `data/infers/<device>_<user>/`。
- 总线、分路文件名正则以配置规范中的 `RE_BUS`、`RE_BR` 为准；算法代码不得自行放宽或改写正则。
- 用户配置示例实际使用“终端号_用户号”复合键，而优先级文字使用 `<user_id>` 占位符；为避免歧义，本版规定生产调度键采用 `user_key=<device>_<user>`，批量状态表仍按接口字段输出 `user_id`。
- 最终预测 CSV、日指标、启动段分析和批量状态表采用附件规定的文件名/字段；算法内部可以使用统一数据对象，但落盘时必须转换为规定接口。
- 附件的日级指标文字写“25 个固定字段”，但当前字段清单实际列出 23 个字段；本版不得擅自补充 2 个字段，以当前明确列出的字段为接口契约，并将该差异记录为接口待确认项。
- 附件启动段字段使用 `being_time`；本版保持该字段名，已确认改为 `begin_time`。
- 附件只规定 15 分钟统一时间尺度，没有规定所有物理量的唯一聚合算法；因此电压/电流/有功功率/PF 的聚合策略作为可配置算法规则，并要求记录实际采用策略。

1. Agent 执行总则

Agent 必须将本指南视为项目级开发规范。开发过程中不得跳过数据可辨识性分析、时间对齐、数据质量检查、Baseline 建立和独立测试。所有自动修改必须保留实验记录、配置、日志、模型版本和评价结果。

- 目标输入：总线侧 5 分钟低频三相电气时序；目标标签：分路侧 15 分钟三相总有功功率。
- 总线每天 288 点；分路每天 96 点；统一建模频率为 15 分钟。
- 严禁把 15 分钟分路真实标签简单插值成 5 分钟训练真值。
- 默认不使用 FFT、THD 等高频波形特征；当前采样粒度不足以支持可靠高频电能质量分析。
- 训练/验证/测试必须避免时间泄漏，优先连续时间段切分。
- 所有实验必须可复现：随机种子、环境、配置、数据版本、特征版本、代码版本、模型权重、指标均须保存。

2. 项目目标与输入输出定义

2.1 业务目标

建立从总线侧低频多变量时序预测一个或多个分路有功功率的监督式负荷辨识系统，对指定未来/推理时间段输出目标分路功率，并提供功率误差、能量误差、状态指标、总线解释能力和行为分析。

2.2 数学定义

统一到 15 分钟后，每天 96 个时间点。总线特征 $X(t)$ 由三相电压、电流、有功功率、功率因素及派生特征组成；标签 $Y(t)$ 为一个或多个目标分路功率。默认 $L=96$ ，即过去 24 小时窗口。

$$X(t)=[UA,UB,UC,IA,IB,IC,PA,PB,PC,PFA,PFB,PFC,derived_features]$$

$$Y(t)=[P1(t),P2(t),\dots,PN(t)]$$

$$f_{\theta} : X(t-L+1:t) \rightarrow \hat{Y}(t-L+1:t), \quad L=96$$

2.3 输入输出验收

项目	要求
总线	5min，288 点/天；具体字段必须经 schema 确认
分路	15min，96 点/天；p1、p2、p3...，单位 W
统一尺度	15min
训练输入	15min 总线多变量窗口+派生/时间特征
训练标签	15min 分路真实有功功率
推理输入	15min 总线数据
最终预测 CSV	必须符合 predictions/inference_result.csv 契约
非负性	原则上非负；若业务允许反送电/负功率，必须显式配置

3. 实际数据输入结构与文件命名

3.1 目录

```
data/
├── trains/
│   ├── <device>_<user>/
│   │   ├── Bus CSV
│   │   └── Branch CSV
└── infers/
    ├── <device>_<user>/
    │   ├── Bus CSV
    │   └── Branch CSV (若存在，仅用于离线评估，不参与生产推理)
```

每个 <device>_<user> 文件夹代表一个独立训练/推理单元。实际用户目录示例：
800080252842_4206894986488。user_key=terminal_id/user_id 复合业务键。

3.2 总线 CSV

必须严格采用接口规范中的 RE_BUS:

```
^e241_(?P<device>[^_]+)_(?P<user>[^-]+)-Ch(?P<ch>\d+)-(?P<start>\d{6})-(?P<end>\d{6})(?P<suffix>(-1|-infer)?)\.csv$
```

示例: e241_800080270708_4206602981958-Ch1-250710-260628.csv。

- 必须包含 event_time, 或能转换为 ISO 时间字符串。
- 通常包含 load_iden_data0、load_iden_data1...或主回路功率与电压特征; 实际字段必须以 schema 检查结果为准。
- device/user 必须与父目录一致。
- ChN 只是通道标识, 禁止假设 Ch1=某一物理量; 物理含义必须通过字段/配置确认。
- 文件名时间只用于初步识别, 最终必须用 CSV 内实际时间戳校验。
- 同一用户多个 Ch 文件必须按时间轴和 channel_id 关联。

3.3 分路 CSV

必须严格采用接口规范中的 RE_BR:

```
^(?P<user>[^-]+)-(?P<start>\d{6})-(?P<end>\d{6})(?P<suffix>(-1|-infer)?)\.csv$
```

示例: 4206602981958-250710-260628.csv。

- 必须包含 time。
- 必须包含 p1、p2、p3、p4...等功率列, 单位 W。
- 支持 target_col=p1 或 p1+p2、p1+p2+p3 等复合目标。
- 复合列按行累加, skipna=False; 任一组成列 NaN 时复合目标为 NaN。
- 目标字符串忽略大小写和空格; 禁止重复分量。
- 分路文件 user 必须与父目录 user_id 一致。

4. 数据接入与字段标准化

Agent 首先扫描 CSV 文件并建立字段映射; 当前接口以 CSV 为准, 不要求自动支持 Excel/数据库。

- 识别时间戳、设备/测点 ID、三相电压、电流、有功功率、功率因素和分路功率字段。
- 统一内部字段名, 例如 timestamp、ua、ub、uc、ia、ib、ic、pa、pb、pc、pfa、pfb、pfc、branch_p。
- 单位检查: V、A、W/kW、功率因素无量纲; 不确定时标记 DATA_UNIT_UNKNOWN, 禁止静默转换。

- 检查 CT/PT 变比、倍率、正负方向和计量口径，倍率必须配置化。
- 输出 data_schema_report.json、data_quality_report.html。

5. 时间同步与 5 分钟→15 分钟

5.1 时间轴

- 统一时区、日期格式和时间精度。
- 建立 15 分钟 canonical timeline：00:00、00:15、...、23:45。
- 分路保持真实 15 分钟采样点，不进行 5 分钟标签插值。
- 总线 5 分钟数据聚合到 15 分钟。

5.2 聚合策略

接口规范只规定统一到 15 分钟，不规定所有变量的唯一聚合算法。实现时必须配置并记录实际策略：

变量	推荐默认	约束
电压 U	mean	可同时生成 std/min/max
电流 I	mean	可同时生成 std/min/max
有功功率 P	mean 或按业务计量定义聚合	必须确认原始 P 的物理定义
PF	优先按 P/S 重新计算；无 S 时采用明确配置策略	禁止无说明直接平均

5.3 时间偏移

即使双方均标称 15 分钟，也必须通过总线总功率、分路功率和事件变化相关性搜索候选滞后 τ 。不得无证据修改时间戳。

6. 数据质量控制

- 时间戳：重复、缺失、乱序、跨日异常。
- 数值：NaN、Inf、超量程、异常负值、长期恒定、突变。
- 三相一致性：电压、电流、有功功率三相分布。
- PF：超范围、长期为 0、与功率状态不一致。
- 分路：缺失比例、连续缺失、长期零值、异常尖峰。
- 总线/分路：覆盖范围、共同时间区间、有效样本量。
- 输出 quality_score、missing_rate、outlier_rate、coverage_rate；原始数据不可覆盖。

7. 电气拓扑与功率口径验证

- 确认总线与分路属于同一供电拓扑和计量范围。
- 确认目标分路是否全部挂在该总线下。
- 确认功率单位、CT/PT 倍率、正负号定义一致。
- 确认总线是否包含大量未采集分路。
- 若存在未监测负荷，不得强制 $P_{bus} = \sum P_i$ 。
- 在拓扑成立时可使用 $P_{bus} \approx \sum P_i + P_{unknown}$ ，并可学习 Unknown Load。

8. 特征工程

8.1 原始特征

UA、UB、UC、IA、IB、IC、PA、PB、PC、PFA、PFB、PFC；若存在 Ptotal，同时保留并检查与 PA+PB+PC 的一致性。

8.2 统计/变化

窗口 mean/std/min/max/range； ΔP 、 ΔI 、 ΔU 、 ΔPF ；相邻 15 分钟变化率；滚动均值、滚动标准差、短期波动强度。

8.3 三相结构

三相电流不平衡度、有功功率不平衡度、各相功率/电流占比、相间差异。

8.4 时间

hour、minute、day_of_week、is_weekend、month、day_of_year，并使用 sin/cos 周期编码；可靠时可增加 holiday/working_day/shift。

8.5 禁用

5/15 分钟级数据不得把 FFT/THD/高频谐波作为核心输入；获得秒级或波形数据后再独立开发高频模块。

9. 负荷可辨识性分析

模型训练前强制执行。

- P_{bus} 与各 P_i 的 Pearson/Spearman 相关性。
- 不同时间滞后 τ 的相关性和最优 τ 。
- 分路间相关性矩阵。
- 各分路 P_i/P_{bus} 贡献率。
- 已知分路之和对总线功率解释率。

- 工作日/周末、昼夜、月份分层分析。
- 低方差、长期关闭、高度同步分路风险识别。
- 高度同步且无额外区分信息时标记 IDENTIFIABILITY_LOW，不得靠增加网络深度掩盖问题。

10. 监督样本构建

- 默认滑动窗口。
- L=96，过去 24 小时。
- 默认 Seq2Seq；可配置 Seq2Point。
- 窗口必须连续、输入与标签严格对齐。
- 严重质量问题窗口不得进入训练。
- 保存样本索引、日期、窗口起止时间。

11. 数据集划分

- 优先按月份或连续日期切分，不随机打散全部时间点。
- 跨季节泛化测试时，Test 应覆盖不同季节/工况。
- Scaler/Normalizer 只能由 Train 拟合。
- 同时遵守 JSON splits 的 include/exclude 硬锚定与排除规则。

12. 用户 JSON 配置契约

入口：python run_batch_users.py --time-filter-config <path_to_json>。

12.1 配置键与优先级

源规范文字使用 config["<user_id>"] 占位符，但示例实际使用“终端号_用户号”复合键。为与实际目录一一对应，本版生产实现统一采用 user_key=<device>_<user> 作为配置键；若现有代码已使用单独 user_id，则必须通过明确映射层兼容，禁止隐式猜测。

优先级：具体 user_key 配置 > _default > common.py/流水线硬编码默认值。以下划线开头的顶级名称（_note_、_comment_、_default）不得作为用户数据名加载。

12.2 配置示例

```
{
  "800080270708_4206602981958": {
    "target_col": "p1+p2",
    "on_thr_w": 50.0,
    "split_ratios": [0.70, 0.15, 0.15],
    "split_strategy": "global_stratified",
    "post_min_on": 2,
    "post_fill_short_off": 3,
```

```

"weather_latitude": 30.59,
"weather_longitude": 114.31,
"use_weather_features": true,
"use_temp_based_season": true,
"train": {
  "include": [["2025-07-10", "2026-06-28"]],
  "exclude": [["2026-04-02 17:45", "2026-04-02 23:59:59"]]
},
"infer": {
  "exclude": [["2026-06-05", "2026-06-05"]]
},
"splits": {
  "train": {"exclude": [["2026-06-12", "2026-06-12"]]},
  "val": {"include": [["2026-06-20", "2026-06-20"]]},
  "test": {"include": [["2026-06-25", "2026-06-25"]]}
},
}_default": {
  "on_thr_w": 10.0,
  "split_ratios": [0.6, 0.2, 0.2],
  "split_strategy": "stratified_day"
}
}

```

12.3 字段规则

字段	规则
target_col	pN 或 pA+pB...; 缺省按接口回退链处理
on_thr_w	[0.001,5000] W; 默认 10
split_ratios	3 个 Float, 总和=1; 默认 [0.6,0.2,0.2]
split_strategy	stratified_day / stratified / time / global_stratified; 默认 stratified_day
post_min_on	>=0; 默认 1
post_fill_short_off	>=0; 默认 3
weather_latitude	[-90,90]; 默认 30.59
weather_longitude	[-180,180]; 默认 114.31
use_weather_features	bool; 默认 true
use_temp_based_season	bool; 默认 true

12.4 时间过滤

- include/exclude 元素为 [start,end] 闭区间。
- YYYY-MM-DD 自动扩展为当天 00:00:00 ~ 23:59:59。
- 先取 include 并集; include 为空表示所有有效行; 再执行 exclude。
- train、infer 均支持独立 include/exclude。
- splits.train/val/test 各自支持 include/exclude。
- 切分顺序: 初始策略切分 → include 硬锚定 → 比例平衡 → exclude 精确排除; include 冲突按 train→val→test。

13. 实际批量用户执行

Agent 自动扫描 data/trains/ 与 data/infers/ 的一级用户目录；每个合法 user_key 生成独立任务。

- 目录不匹配 $^([0-9]+)_([0-9]+)\$$ 时标记 INVALID_USER_DIR。
- train 缺总线：DATA_MISSING_BUS；缺分路标签：DATA_MISSING_BRANCH_LABEL。
- 文件名解析失败：INVALID_FILENAME。
- 目录与文件身份不一致：IDENTITY_MISMATCH。
- 数据范围不足：INSUFFICIENT_TIME_RANGE。
- 质量不合格：DATA_QUALITY_FAILED。
- 推理找不到匹配模型：MODEL_NOT_FOUND；不得随机使用其他用户模型。
- 单用户失败不得阻塞其他用户；必须支持断点续跑。
- 原始 data/trains 和 data/infers 不得移动、重命名或覆盖。